

**UT
CB**



Universitatea Tehnică de Construcții București

**Facultatea de Construcții Civile,
Industriale și Agricole**

Lucrare de disertație

Aplicații ale rețelelor neuronale artificiale în ingineria civilă

Conducătorul lucrării de disertație
Prof. univ. dr. ing. Sorin Demetriu

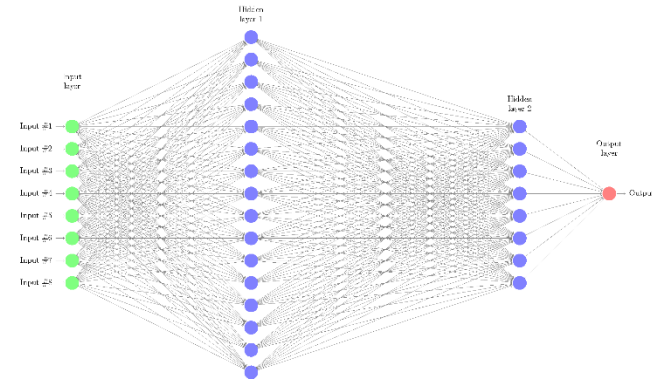





Ing. Paul Ionescu

București
2018






Cuprins

- I. Introducere AI
- II. Rețele neuronale artificiale (ANN)
- III. Clasificare binară - ANN
- IV. Regresie neliniară - ANN
- V. Rețele neuronale artificiale recurente – RNN
- VI. Concluzii

I. Introducere AI





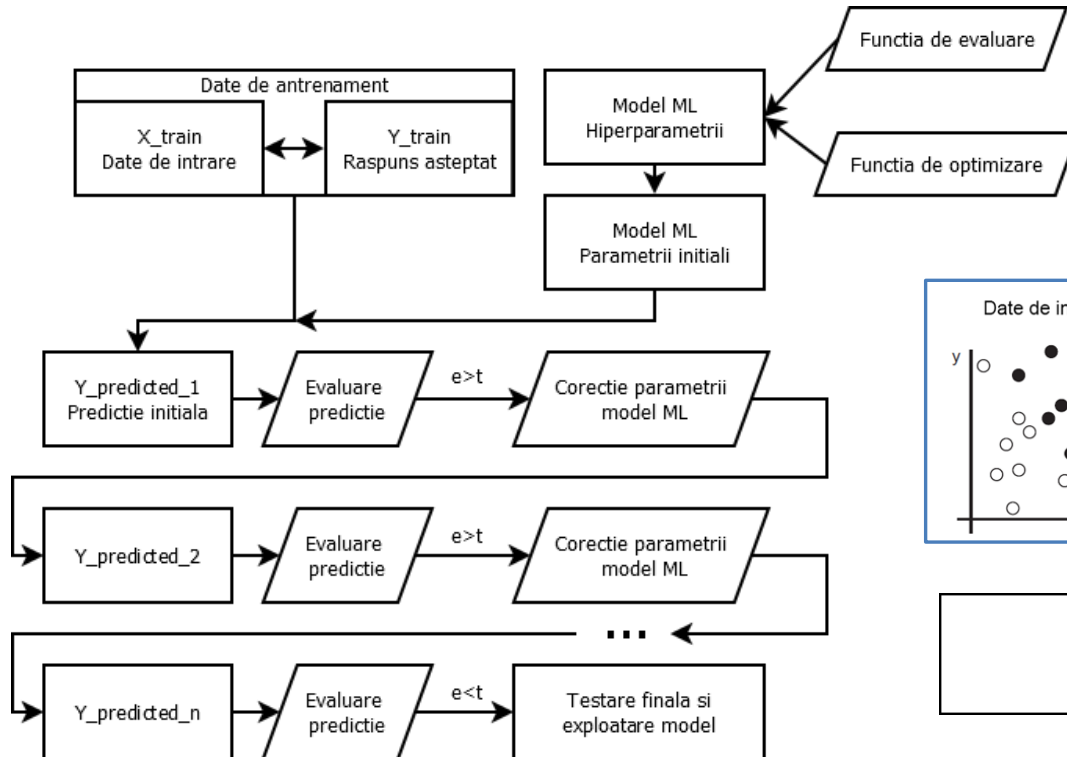
I. Introducere AI



$$z = c + a \times x + b \times y$$


$$z = \text{[Neural Network Layer]} + \text{[Neural Network Layer]} \times x + \text{[Neural Network Layer]} \times y$$

I. Introducere AI

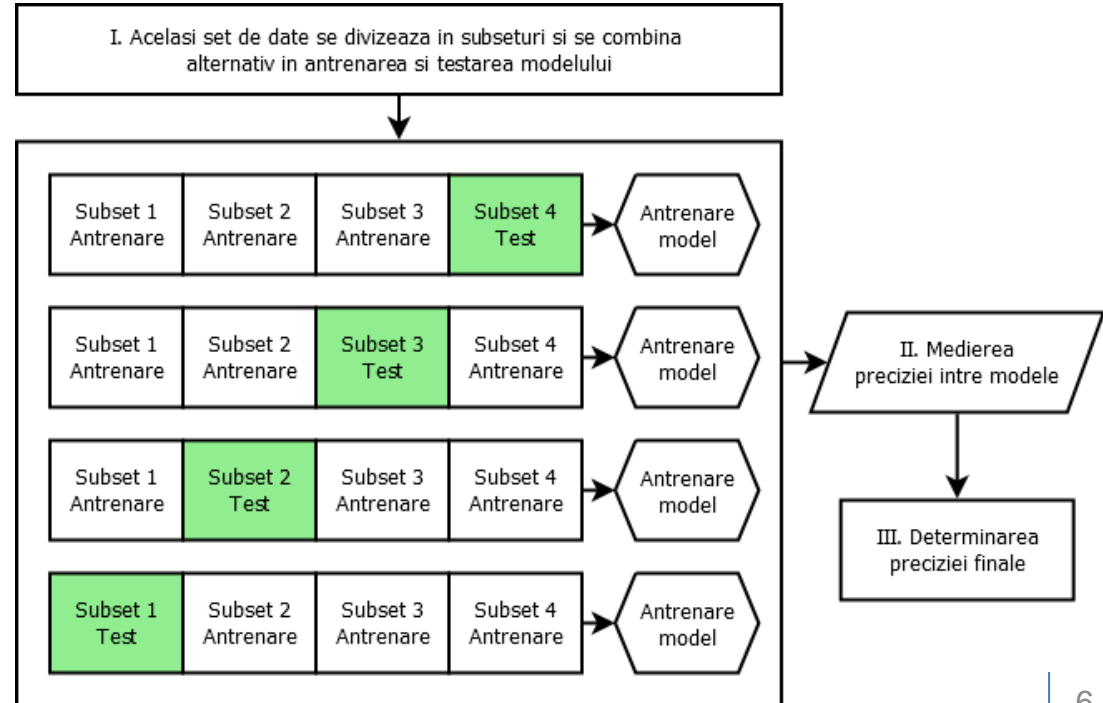


I. Introducere AI

Abordarea clasică de validare




Procedura de cross-validare




II. Rețele neuronale artificiale

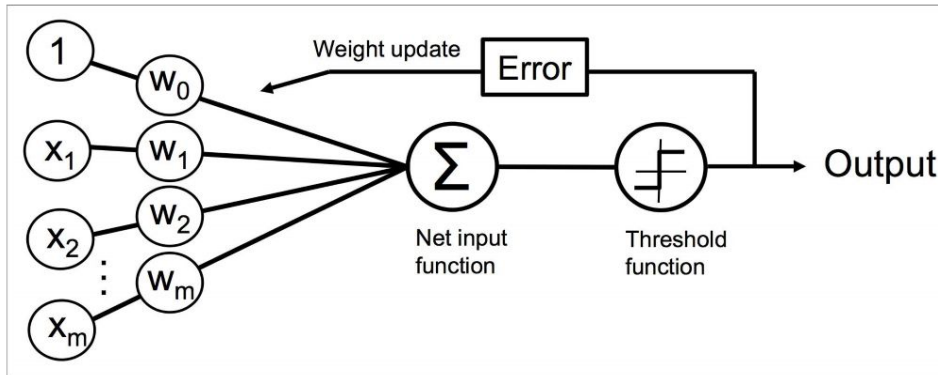
Neuronul natural



[Arizona state university]




Neuronul artificial



$$h_n = f\left(\sum_{i=0}^m x_i * w_i\right) \quad (\text{activitatea neuronală})$$

$$f(t) = \frac{1}{1 + e^{-t}} \quad (\text{funcția de activare})$$





Metoda de propagare înapoi a erorii – Backpropagation


$$J(w) = MSE(w) = \frac{1}{n} \sum_{i=1}^n (o_i - h_i)^2 \quad (\text{funcția de Loss})$$

$$K(w) = w - \eta \nabla J(w) \quad (\text{funcția de optimizare})$$


Activitatea neuronală – vizualizare grafică




[Flood 1994]




(a)




(b)



(c)



(d)



(e)

III. Clasificare binară - ANN

Aplicația I - Lichefierea terenului

Previzualizare set de date:

	mag	s0	sp0	spt	ag	tau_dinamic	pfine	d50	outcome
0	7.9	186.4	96.1	20.0	0.32	0.36	0	0.46	1
1	7.9	130.5	81.4	10.0	0.32	0.32	5	0.28	1
2	7.9	111.8	71.6	17.0	0.28	0.28	3	0.80	1
3	7.9	93.2	67.7	13.0	0.28	0.25	4	0.60	1
4	7.9	122.6	93.2	10.0	0.20	0.16	10	0.25	1


Dimensiuni set de date = (85, 9)

[Goh 1993]

Legenda

- (1) mag = M - magnitudine cutremur
- (2) s0 = σ_0 - efort vertical total
- (3) sp0 = σ'_0 - efort vertical efectiv
- (4) spt = $(N_1)_{60}$ - valoare test SPT normalizat
- (5) ag = $\frac{a}{g}$ - acceleratie maxima orizontala normalizata la g
- (6) tau_dinamic = $\frac{\tau_{av}}{\sigma'_0}$ - efort de forfecare dinamic echivalent la adancimea z
- (7) pfine=F(%) - procentul de particule fine
- (8) d50 = D_{50} - granulometria mediana a pamantului
- (9) outcome - 1 = Lichefiere / 0 = Nu sa produs lichefierea solului

Matricea de corelație a parametrilor



III. Clasificare binară - ANN

Aplicația I - Lichefierea terenului dintr-un amplasament

Previzualizare set de date:

	mag	s0	sp0	spt	ag	tau_dinamic	pfine	d50	outcome
0	7.9	186.4	96.1	20.0	0.32	0.36	0	0.46	1
1	7.9	130.5	81.4	10.0	0.32	0.32	5	0.28	1
2	7.9	111.8	71.6	17.0	0.28	0.28	3	0.80	1
3	7.9	93.2	67.7	13.0	0.28	0.25	4	0.60	1
4	7.9	122.6	93.2	10.0	0.20	0.16	10	0.25	1

Dimensiuni set de date = (85, 9)

Legenda

(1) mag = M - Magnitudine Richter cutremur

(2) s0 = σ_0 - Efort vertical total (kPa)

(3) sp0 = σ'_0 - Efort vertical efectiv (kPa)

(4) spt = $(N_1)_{60}$ - Valoare test SPT normalizat

(5) ag = $\frac{a}{g}$ - Acceleratie maxima orizontala normalizata la g

(6) tau_dinamic = $\frac{\tau_{av}}{\sigma'_0}$ - Efort de forfecare dinamic echivalent la adancimea z

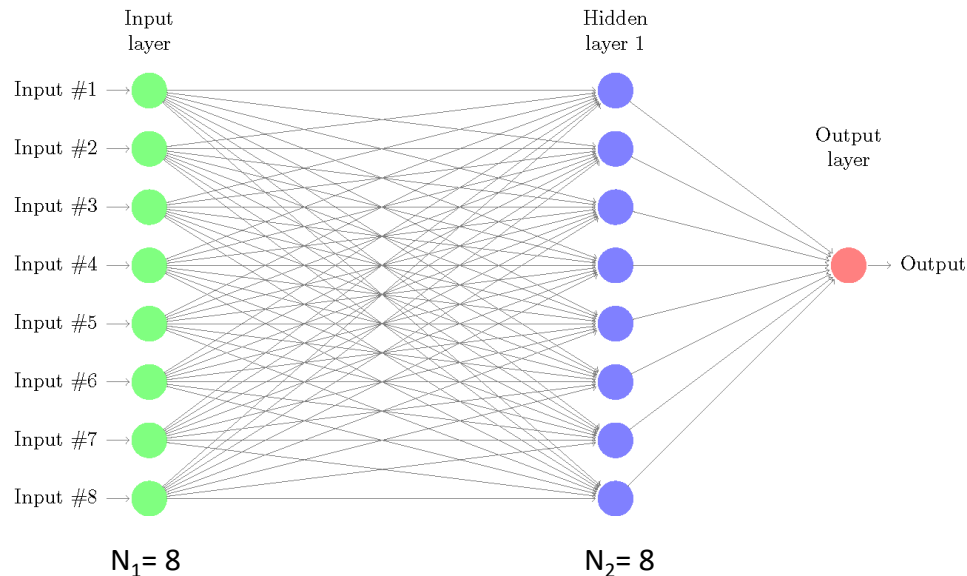
(7) pfine=F(%) - Procentul de particule fine

(8) d50 = D_{50} - Diametrul median al particulelor(mm)

(9) outcome - 1 = Lichefiere / 0 = Nu s-a produs lichefierea

$$\tau_{av} = \frac{\tau_{av}}{\sigma'_0} = 0.1 \frac{a}{g} (M - 1) \frac{\sigma_0}{\sigma'_0} (1 - 0.015z)$$

Topologia rețelei neuronale artificiale folosită



Epoch
000,000

Learning rate

0.03

Activation

Sigmoid

Regularization

None

Regularization rate

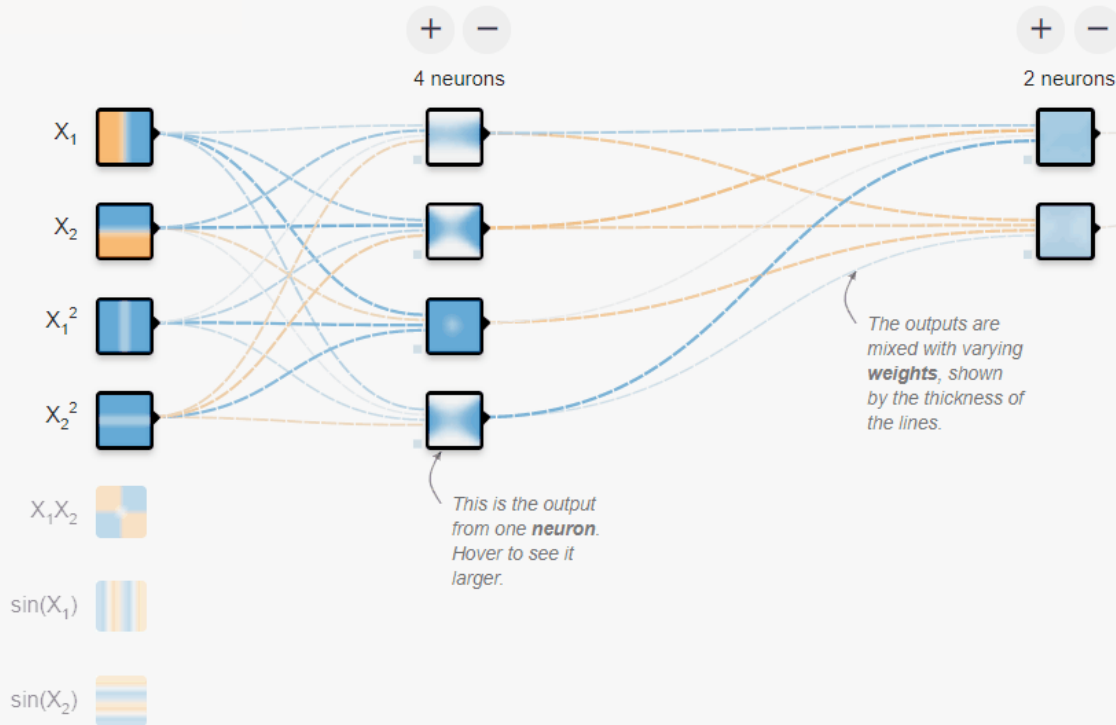
0

Problem type

Classification

[Tensorflow Playground]


+ - 2 HIDDEN LAYERS




OUTPUT

Test loss 0.501


Training loss 0.503



Colors shows
data, neuron and
weight values.




Rezultate - Aplicația 1



Mărime set de date de antrenare: 59

Mărime set de date de antrenare: 26 (30% din setul total)

Din cele 26 cazuri de test au fost clasificate corect 24 (92.3%)



Sumar rezultate

	Goh	Studiu curent
Precizie pentru datele de antrenare	97%	98.3%
Precizie pentru datele de testare	92%	92.3%
Precizie generala	95%	96.5%

Aplicația 1 – Studiu parametric

Cazul particular 1:

$$M = 7.5, \sigma'_0 = 70kPa,$$





$$D_{50} = f(F(\%)), \frac{\tau_{av}}{\sigma'_0} = 0.1, \frac{a}{g} = 0.1$$

Cazul particular 2:

$$M = 7.5, \sigma'_0 = 70kPa,$$

$$D_{50} = f(F(\%)), \frac{\tau_{av}}{\sigma'_0} = 0.2, \frac{a}{g} = 0.2$$

În ambele cazuri se observă relația de proporționalitate inversă între valoarea SPT și probabilitatea de lichefiere.



IV. Regresie neliniară - ANN

Aplicația II – Rezistența axială a specimenelor din beton. Studiul influenței scalării datelor de intrare


Previzualizare set de date:

	cement	slag	fly_ash	water	superplasticizer	coarse_aggregate	fine_aggregate	age	strength
0	540.0	0.0	0.0	162.0	2.5	1040.0	676.0	28	79.99
1	540.0	0.0	0.0	162.0	2.5	1055.0	676.0	28	61.89
2	332.5	142.5	0.0	228.0	0.0	932.0	594.0	270	40.27
3	332.5	142.5	0.0	228.0	0.0	932.0	594.0	365	41.05
4	198.6	132.4	0.0	192.0	0.0	978.4	825.5	360	44.30

Dimensiuni set de date = (1030, 9)


[University of California Irvine]

Topologia rețelei neuronale artificiale




Aplicația II - Rezultate


Evoluția funcției de loss




Epochs 0->300



Epochs 1000->4000



Importanța scalării datelor de intrare - Vizualizare grafică



Este observată o creștere a precizie de aproximativ 10% în urma scalării datelor de intrare.

IV. Regresie neliniară - ANN

Aplicația III – Grindă perete - forța tăietoare capabilă. Studiu parametric al topologiei rețelei

Previzualizare set de date:


	b	h	d	fc	fy	fyv	rpl	rl	rv	rh	s	apd	vtest
0	36.0	48.0	40.0	4100	67	61	0.0043	0.0293	0.0031	0.0030	11.0	1.85	1128.3
1	36.0	48.0	40.0	4100	67	61	0.0043	0.0293	0.0086	0.0030	4.0	1.85	1426.0
2	36.0	48.0	40.0	2800	65	63	0.0043	0.0293	0.0022	0.0022	10.0	1.85	1102.0
3	36.0	48.0	40.0	3000	65	63	0.0043	0.0293	0.0031	0.0030	11.0	1.85	930.0
4	36.0	48.0	40.0	4900	68	62	0.0022	0.0293	0.0031	0.0027	11.0	1.85	1096.0

Dimensiuni set de date = (179, 13)

[Bircher 2009]

Legenda

- (1) b - latime grinda (in)
- (2) h - inaltime grinda (in)
- (3) d - inaltime utila (in)
- (4) fc - rezistenta la compresiune a betonului(psi)
- (5) fy - rezistenta la intindere a armaturilor longitudinale(ksi)
- (6) fyv - rezistenta la intindere a armaturilor transversale(ksi)
- (7) rpl - procentul armaturii longitudinale intinse
- (8) rl - procentul armaturii longitudinale comprimate
- (9) rv - procentul armaturii transversale verticale
- (10) rh - procentul armaturii transversale orizontale
- (11) s - pasul etrierilor (in)
- (12) apd - a/d raportul dintre distanta de aplicare a fortei taietoare și inaltimea utila a grinzii
- (13) vtest - forta taietoare maxima (include greutatea proprie)(kips)



IV. Regresie neliniară - ANN

Aplicația III – Grindă perete - forța tăietoare capabilă. Studiu parametric al topologiei rețelei

Previzualizare set de date:

	b	h	d	fc	fy	fyv	rpl	rl	rv	rh	s	apd	vtest
0	36.0	48.0	40.0	4100	67	61	0.0043	0.0293	0.0031	0.0030	11.0	1.85	1128.3
1	36.0	48.0	40.0	4100	67	61	0.0043	0.0293	0.0086	0.0030	4.0	1.85	1426.0
2	36.0	48.0	40.0	2800	65	63	0.0043	0.0293	0.0022	0.0022	10.0	1.85	1102.0
3	36.0	48.0	40.0	3000	65	63	0.0043	0.0293	0.0031	0.0030	11.0	1.85	930.0
4	36.0	48.0	40.0	4900	68	62	0.0022	0.0293	0.0031	0.0027	11.0	1.85	1096.0

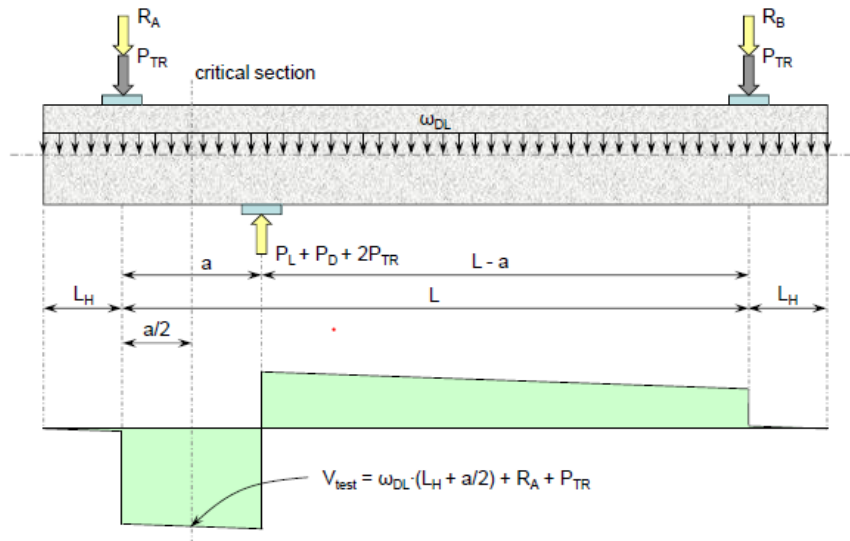
Dimensiuni set de date = (179, 13)

[Bircher 2009]


Legenda

- (1) b - latime grinda (in)
- (2) h - inaltime grinda (in)
- (3) d - inaltime utila (in)
- (4) fc - rezistenta la compresiune a betonului(psi)
- (5) fy - rezistenta la intindere a armaturilor longitudinale(ksi)
- (6) fyv - rezistenta la intindere a armaturilor transversale(ksi)
- (7) rpl - procentul armaturii longitudinale intinse
- (8) rl - procentul armaturii longitudinale comprimate
- (9) rv - procentul armaturii transversale verticale
- (10) rh - procentul armaturii transversale orizontale
- (11) s - pasul etrierilor (in)
- (12) apd - a/d raportul dintre distanta de aplicare a fortei taietoare și inaltimea utila a grinzii
- (13) vtest - forta taietoare maxima (include greutatea proprie)(kips)

Schema statică a experimentului

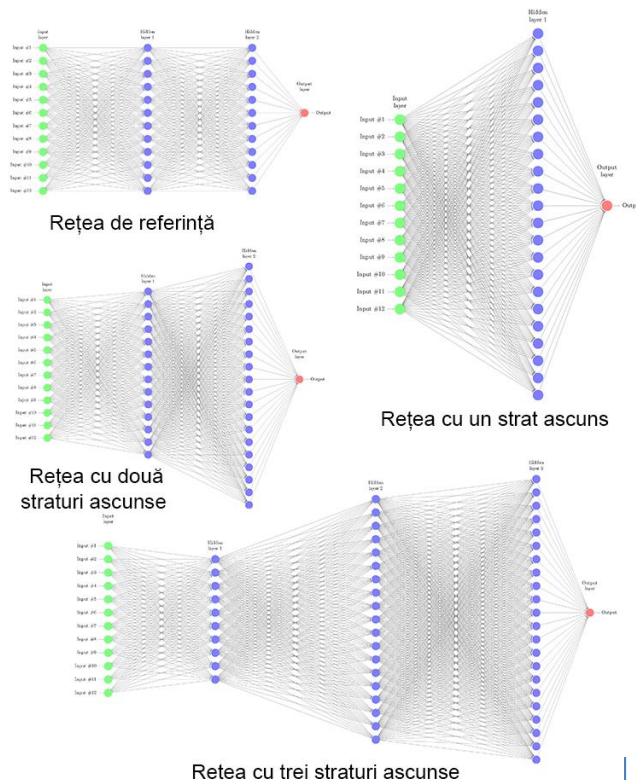


Aplicația III – Grinda perete – Studiu topologie




Sumar rezultate

	Model	Timp antrenare	Precizie test	Nr. epoci	Total neuroni
1	(Referință)	6.9 minute	86%	1857	24
2	(1 S.a.)	9.5 minute	85%	7455	22
3	(2 S.a.)	29.9 minute	90%	21165	34
4	(3 S.a.)	6.2 minute	81%	905	51




Aplicația III – Grinda perete – Studiu topologie

Comparație precizie în funcție de numărul de neuroni




Se constată necesitatea studierii în amănunt a topologiei. Numărul ridicat de neuroni nu conduce neapărat la creșterea preciziei modelului.

Comparație precizie în funcție de perioada de antrenare



Creșterea preciziei conduce la creșterea semnificativă a timpului de antrenare. O creștere de 1% a preciziei conduce la o extindere de 100% a timpului de antrenare.


Vizualizare grafică a ponderilor din stratul ascuns de-a lungul epocilor de antrenament



Modelul 2 - Rețea cu un singur strat ascuns

Se observă tendința de uniformizare.

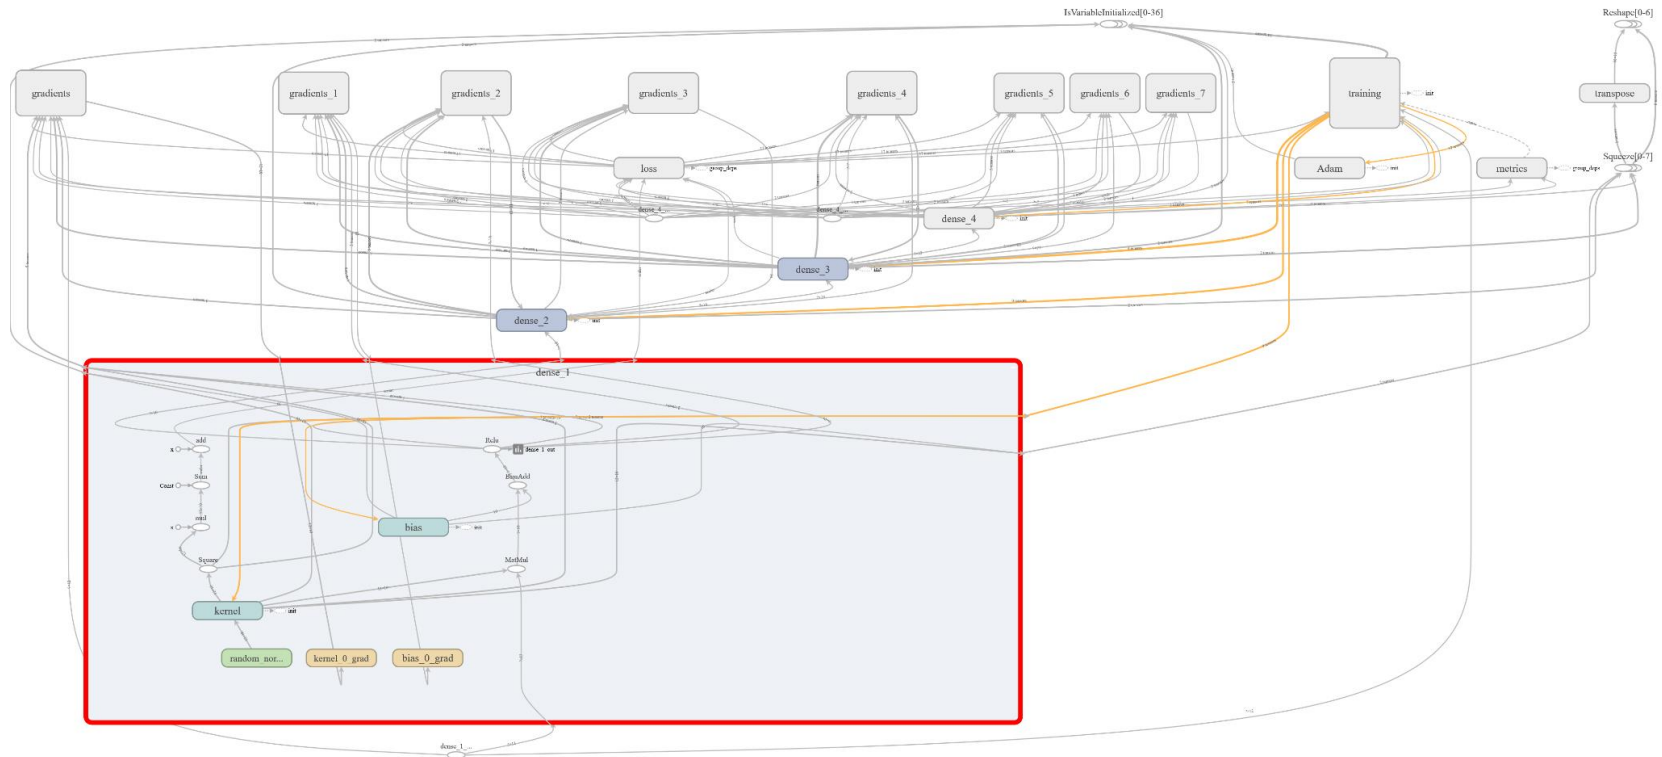
Evoluția histogrammei ponderilor din stratul ascuns de-a lungul epocilor de antrenament



Modificarea ponderilor este pronunțată în primele epoci de antrenament. Se constată tendința de netezire spre finalul antrenamentului.


Aplicația III – Grinda perete – Rețeaua III

Graful general de calcul




V. Rețele neuronale artificiale recurente

Exemplu topologie
rețea recurentă




Algoritmul BPTT
(Backpropagation through time)




V. Rețele neuronale artificiale recurente

Exemplu topologie
rețea recurentă



Celula LSTM
(Long Short Term Memory)



[C. Olah]

V. Rețele neuronale artificiale recurente

Aplicația IV – Predicția vitezei de referință a vântului

Previzualizare set de date
Primele 3 intrări

	YEARMODA	TEMP	WDSP	MXSPD
0	19520101	41.5	3.0	6.0
1	19520102	40.5	3.4	9.9
2	19520103	40.5	1.5	4.1

Ultimele 3 intrari

	YEARMODA	TEMP	WDSP	MXSPD
21304	20180602	68.3	3.9	7.8
21305	20180603	68.1	3.8	7.8
21306	20180604	67.9	2.5	3.9

Dimensiuni set de date initial= (21307, 4)

[NOAA - Constanta]

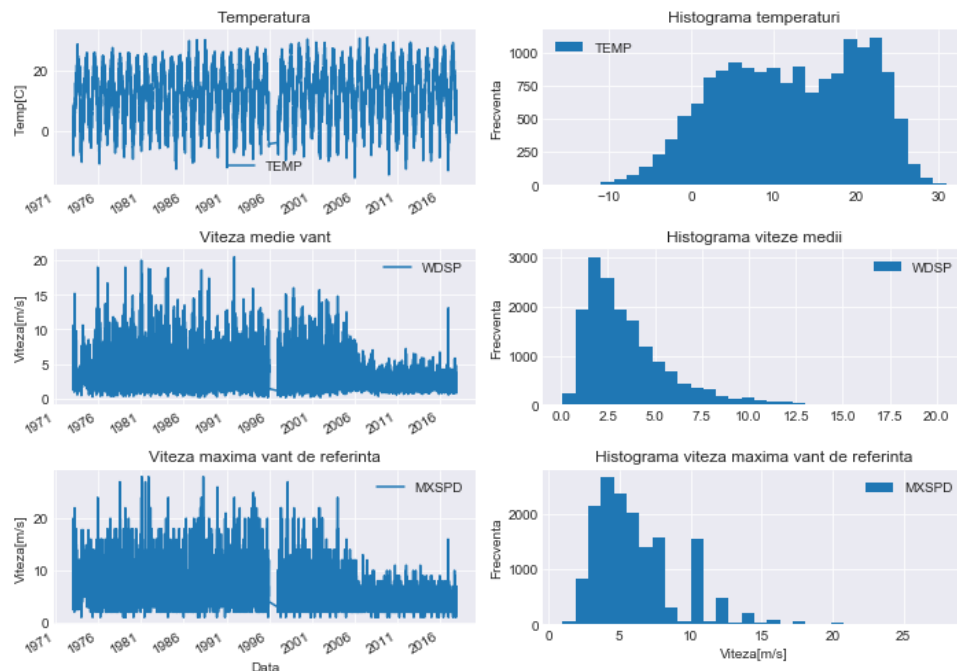
Legenda

TEMP = Temperatura medie zilnică (*F)


MXSPD= Viteza maximă zilnică a vântului de referință (noduri)

WDSP = Viteza medie zilnică a vântului (noduri)

Analiză exploratorie a datelor



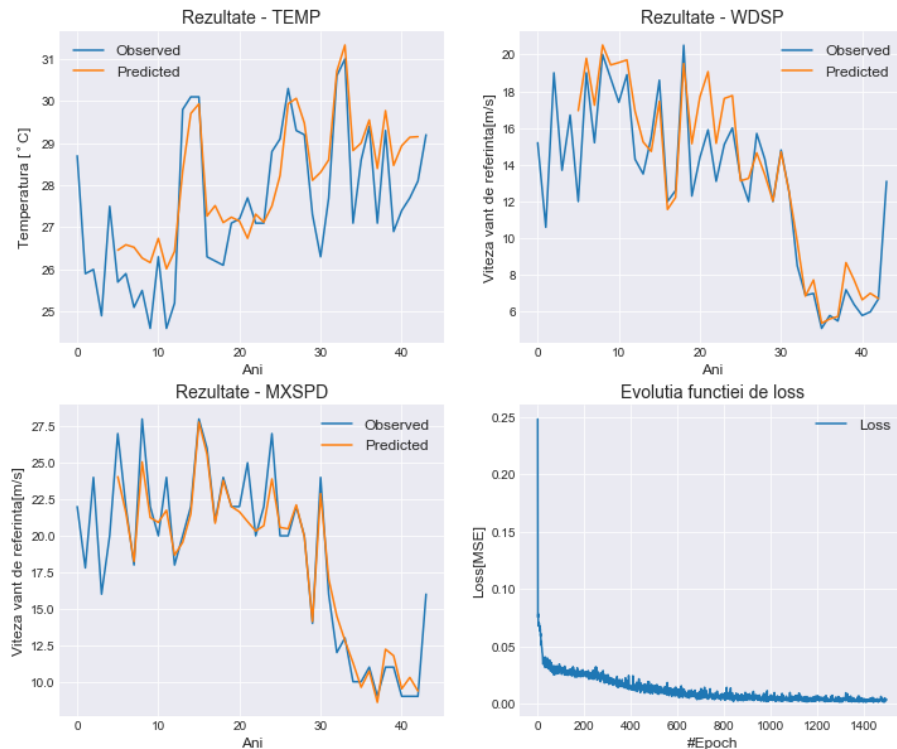

Aplicația IV – Predicția vitezei de referință a vântului





Aplicația IV – Predicția vitezei de referință a vântului

Rezultatele antrenării modelului tridimensional



Rezultatele antrenării modelului unidimensional



Aplicația IV – Predicția vitezei de referință a vântului



Aplicația IV – Predicția vitezei de referință a vântului



Sumar indicatori statistici

Set	μ	σ	CV	Skew	Kurt	u	α
Initial	18.535	5.809	0.313	1.14	2.4	15.559	5.588
Extins - ann1	17.077	6.161	0.361	1.14	2.4	14.027	5.418
Extins - ann3	17.28	5.948	0.344	1.14	2.4	14.345	5.172

VI. Concluzii

- Utilizarea ANN este justificată doar dacă se dispun în prealabil seturi de date extinse
- Este necesară controlarea abilității de generalizare a modelului prin evitarea supra-modelării datelor de intrare (overfitting) și utilizarea procedurii de cross-validare
- Pentru creșterea preciziei este de preferat scalarea datelor de intrare
- Sunt necesare studii ale topologiei. Aceasta depinde teoretic de fenomenul fizic studiat
- După un anumit prag creșterea preciziei de predicție conduce la o extindere majoră a timpului de antrenare

Contribuții personale:

- Prezentarea aspectelor teoretice
- Confirmarea unor studii de referință din sfera aplicațiilor ingineresti
- Abordare modernă în studiul serilor de date (Celule LSTM)

Vă mulțumesc pentru atenție!

Paul Ionescu

Aplicații ale rețelelor neuronale artificiale în ingineria civilă